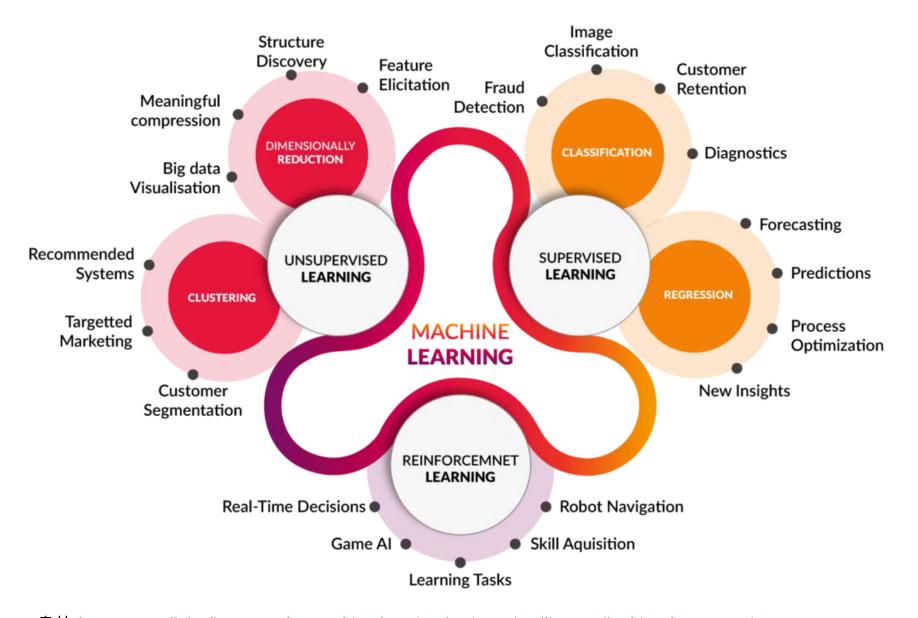
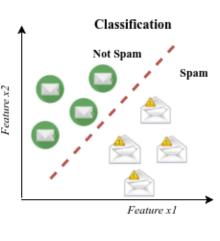
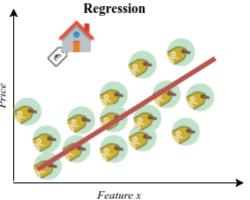
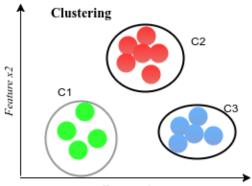
사이킷런으로 시작하는 머신러닝 Chapter 02









Feature x1

※ 출처: https://www.linkedin.com/pulse/machine-learning-business-intelligence-ibrahim-devops-engineer/

※ 출처: https://www.researchgate.net/figure/Examples-of-real-life-problems-in-the-context-of-supervised-and-unsupervised-learning_fig8_319093376





scikit-learn

Machine Learning in Python

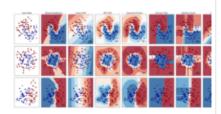
Getting Started Release Highlights for 0.24 GitHub

- Simple and efficient tools for predictive data analysis
- Accessible to everybody, and reusable in various contexts
- Built on NumPy, SciPy, and matplotlib
- Open source, commercially usable BSD license

Classification

Identifying which category an object belongs to.

Applications: Spam detection, image recognition. Algorithms: SVM, nearest neighbors, random forest, and more...

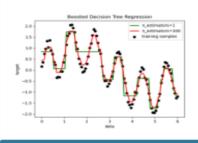


Examples

Regression

Predicting a continuous-valued attribute associated with an object.

Applications: Drug response, Stock prices. Algorithms: SVR, nearest neighbors, random forest, and more...



Examples

Clustering

Automatic grouping of similar objects into sets.

Applications: Customer segmentation, Grouping experiment outcomes

Algorithms: k-Means, spectral clustering, meanshift, and more...

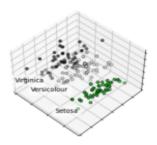


Examples

Dimensionality reduction

Reducing the number of random variables to consider.

Applications: Visualization, Increased efficiency Algorithms: k-Means, feature selection, nonnegative matrix factorization, and more...



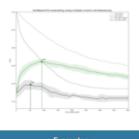
Examples

Model selection

Comparing, validating and choosing parameters and models.

Applications: Improved accuracy via parameter

Algorithms: grid search, cross validation, metrics, and more...



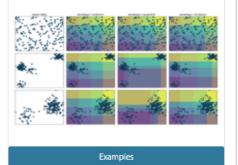
Examples

Preprocessing

Feature extraction and normalization.

Applications: Transforming input data such as text for use with machine learning algorithms.

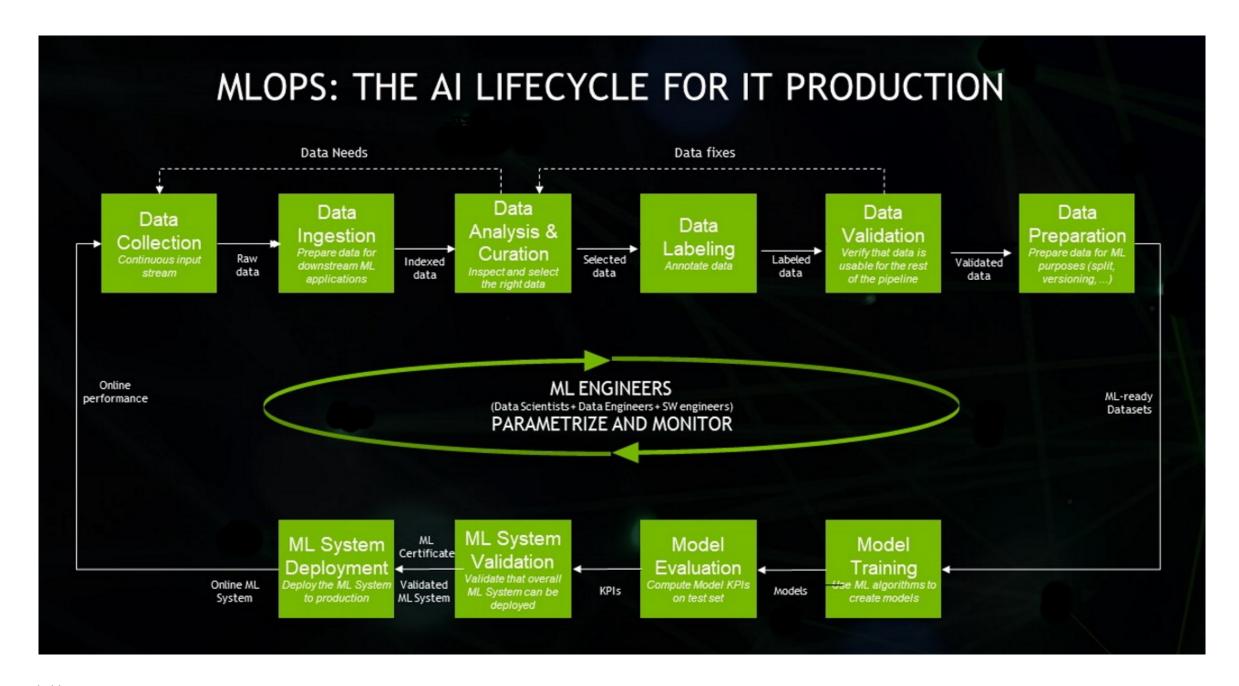
Algorithms: preprocessing, feature extraction, and more...

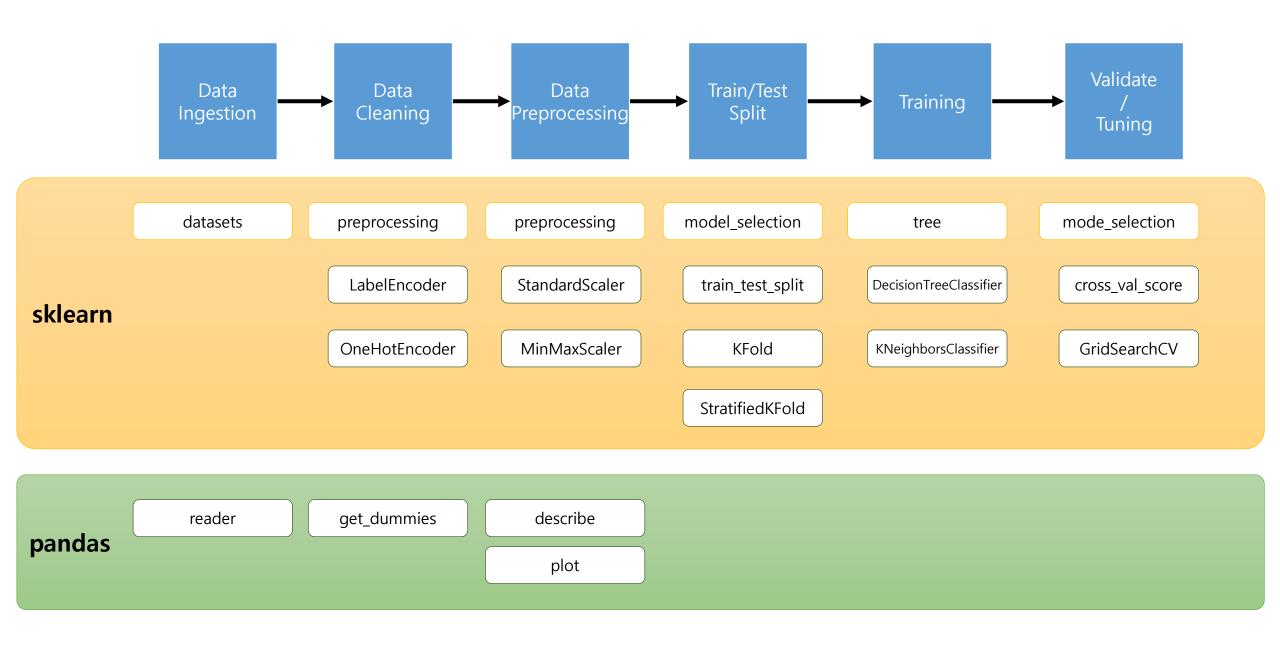


https://scikit-learn.org/

scikit-learn 주요 모듈

분류	모듈명	설명	
예제 데이터	sklearn.datasets	사이킷런에 내장되어 예제로 제공하는 데이터 세트	
	sklearn.preprocessing	데이터 전처리에 필요한 다양한 가공 기능 제공(문자열을 숫자형 코드 값으로 인코딩, 정규화, 스케일링 등)	
	sklearn.feature_selection	알고리즘에 큰 영향을 미치는 피처를 우선순위대로 셀렉션 작업을 수행하는 다양한 기능 제공	
피처처리	sklearn.feature_extraction	텍스트 데이터나 이미지 데이터의 벡터화된 피처를 추출하는데 사용됨. 예를 들어 텍스트 데이터에서 Count Vectorizer나 Tf-ldf Vectorizer 등을 생성하는 기능 제공. 텍스트 데이터의 피처 추출은 sklearn.feature_extraction.text 모듈에, 이미지 데이터의 피처 추출은 sklearn.feature_extraction.image 모듈에 지원 API가 있음	
피처 처리 & 차원 축소	sklearn.decomposition	차원 축소와 관련한 알고리즘을 지원하는 모듈이다. PCA, NMF, Truncated SVD 등을 통해 차원 축소 기능을 수행할 수 있다.	
데이터 분리, 검증 & 파라미터 튜닝	sklearn.model_selection	교차 검증을 위한 학습용/테스트용 분리, 그리드 서치(Grid Search)로 최적 파라미터 추출 등의 API 제공	
평가 sklearn.metrics 분류, 회귀, 클러스터링, 페어와이즈(Pairwise)에 대한 다양한 성능 측정 Accuracy, Precision, Recall, ROC-AUC, RMSE 등 제공		분류, 회귀, 클러스터링, 페어와이즈(Pairwise)에 대한 다양한 성능 측정 방법 제공. Accuracy, Precision, Recall, ROC-AUC, RMSE 등 제공	
	sklearn.ensemble	앙상블 알고리즘 제공. 랜덤 포레스트, 에이다 부스트, 그래디언트 부스팅 등을 제공	
	sklearn.linear_model	주로 선형 회귀, 릿지(Ridge), 라쏘(Lasso) 및 로지스틱 회귀 등 회귀 관련 알고리즘을 지원. 또한 SGD(Stochastic Gradient Desccent) 관련 알고리즘도 제공	
	sklearn.naïve_bayes	나이브 베이즈 알고리즘 제공. 가우시안 NB. 다항 분포 NB 등	
ML 알고리즘	sklearn.neighbors	최근접 이웃 알고리즘 제공. K-NN(K-Nearest Neighborhood) 등	
	sklearn.svm	서포트 벡터 머신 알고리즘 제공	
	sklearn.tree	의사 결정 트리 알고리즘 제공	
	sklearn.cluster	비지도 클러스터링 알고리즘 제공 (K-평균, 계층형, DBSCAN 등)	
유틸리티	sklearn.pipeline	피처 처리 등의 변환과 ML 알고리즘 학습, 예측 등을 함께 묶어서 실행할 수 있는 유틸리티 제공	





Data Ingestion

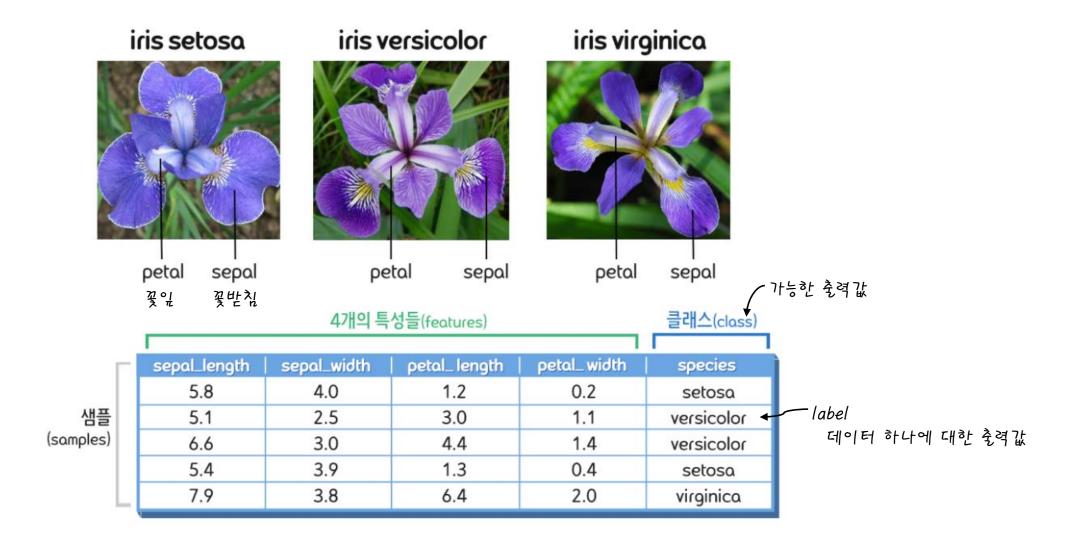
sklearn: datasets

구분	API	Туре	Comments
	datasets.load_boston()	Regession	미국 보스턴 집 특성 및 가격
내장 예제 데이터 세트	datasets.load_breast_cancer()	Classification	위스콘신 유방암 특성 및 악성/음성 레이블 포함
	datasets.load_diabetes()	Regession	당뇨
	datasets.load_digits()	Classification	0~9 숫자 이미지 픽셀
	datasets.load_iris()	Classification	붓꽃 특성 및 분류 정보 포함
원격 다운로드 데이터 세트	datasets.fetch_covtype()	Regession	토지 조사 내용
	datasets.fetch_20newsgroups()		뉴스 그룹 텍스트
	datasets.fetch_olivertti_faces()		얼굴 이미지
	datasets.fetch_lfw_people()		얼굴 이미지
	datasets.fetch_lfw_pairs()		얼굴 이미지
	datasets.fetch_rcv1()		로이터 뉴스 말뭉치
	datasets.fetch_mldata()		ML 웹사이트에서 다운로드
표본 데이터 생성	datasets.make_classifications()	Classification	분류를 위한 데이터 세트 생성
	datasets.make_blobs()	Clustering	클러스터링을 위한 데이터 세트 생성

pandas : reader (I/O API)

Format Type	Data Description	Reader	Writer
text	CSV	read_csv	to_csv
text	Fixed-Width Text File	read_fwf	
text	JSON	read_json	to_json
text	HTML	read_html	to_html
text	Local clipboard	read_clipboard	to_clipboard
binary	MS Excel	read_excel	to_excel
binary	OpenDocument	read_excel	
binary	HDF5 Format	read_hdf	to_hdf
binary	Feather Format	read_feather	to_feather
binary	Parquet Format	read_parquet	to_parquet
binary	ORC Format	read_orc	
binary	Msgpack	read_msgpack	to_msgpack
binary	Stata	read_stata	to_stata
binary	SAS	read_sas	
binary	SPSS	read_spss	
binary	Python Pickle Format	read_pickle	to_pickle
SQL	SQL	read_sql	to_sql
SQL	Google BigQuery	read_gbq	to_gbq

iris data (붓꽃 데이터)



실습

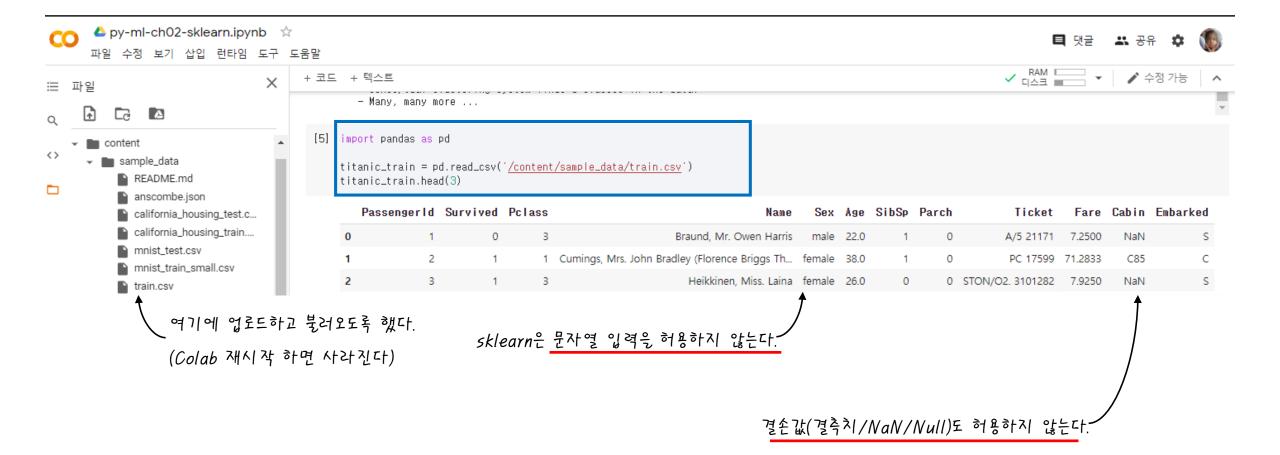
```
from sklearn.datasets import load_iris
iris = load_iris()
print(iris.DESCR)
.. _iris_dataset:
Iris plants dataset
**Data Set Characteristics:**
    :Number of Instances: 150 (50 in each of three classes)
    :Number of Attributes: 4 numeric, predictive attributes and the class
    :Attribute Information:
       - sepal length in cm
       - sepal width in cm
       - petal length in cm
       - petal width in cm
       - class:
               - Iris-Setosa
               - Iris-Versicolour
               - Iris-Virginica
    :Summary Statistics:
                                          Class Correlation
    sepal length: 4.3 7.9
                             5.84
                                    0.83
                                             0.7826
                   2.0 4.4
                              3.05
                                    0.43
                                            -0.4194
    sepal width:
    petal length: 1.0 6.9 3.76
                                    1.76
                                            0.9490 (high!)
                   0.1 2.5
                                    0.76
                                             0.9565 (high!)
    :Missing Attribute Values: None
    :Class Distribution: 33.3% for each of 3 classes.
```

:Donor: Michael Marshall (MARSHALL%PLU@io.arc.nasa.gov)

:Creator: R.A. Fisher

:Date: July, 1988

실습



Data Cleaning

sklearn: preprocessing - LabelEncoder



입력은 숫자로 해줘야 하기에 문자열은 숫자로 변경해야 한다.

transformer 계열든은 "fit() → transform()" 으로 구현된다.

숫자로 변형된 값의 원본은 확인하고 싶으면 "inverse_transform" 사용하면 된다. encoder.inverse_transform(titanic_train['Sex_encoded'])

그런데, 사실 scikit-learn에서 문자열은 넣어줘도 알아서 해준다. (해보면 된다)

```
        titanic_train.head(3)

        PassengerId Survived Pclass
        Name Sex_encoded

        0
        1
        0
        3
        Braund, Mr. Owen Harris
        1

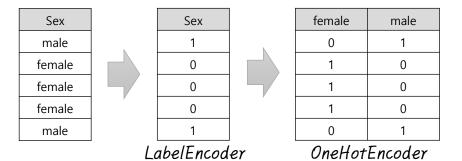
        1
        2
        1
        1
        Cumings, Mrs. John Bradley (Florence Briggs Th...
        0

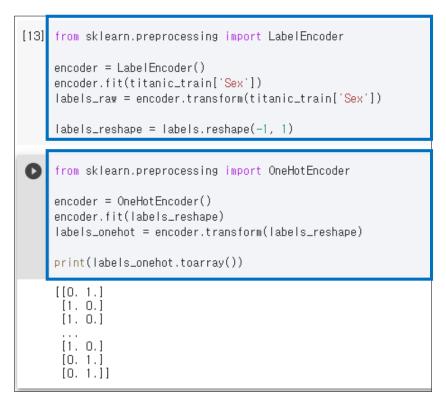
        2
        3
        1
        3
        Heikkinen, Miss. Laina
        0
```

```
[5] print(titanic_train['Sex'])
             male
            female
           female
            female
             male
             male
            female
            female
             male
             male
    Name: Sex, Length: 891, dtype: object
    from sklearn.preprocessing import LabelEncoder
    encoder = LabelEncoder()
    encoder.fit(titanic_train['Sex'])
    titanic_train['Sex_encoded'] = encoder.transform(titanic_train['Sex'])
    print(titanic_train['Sex_encoded'])
    889
    Name: Sex_encoded, Length: 891, dtype: int64
```

sklearn: preprocessing - OneHotEncoder







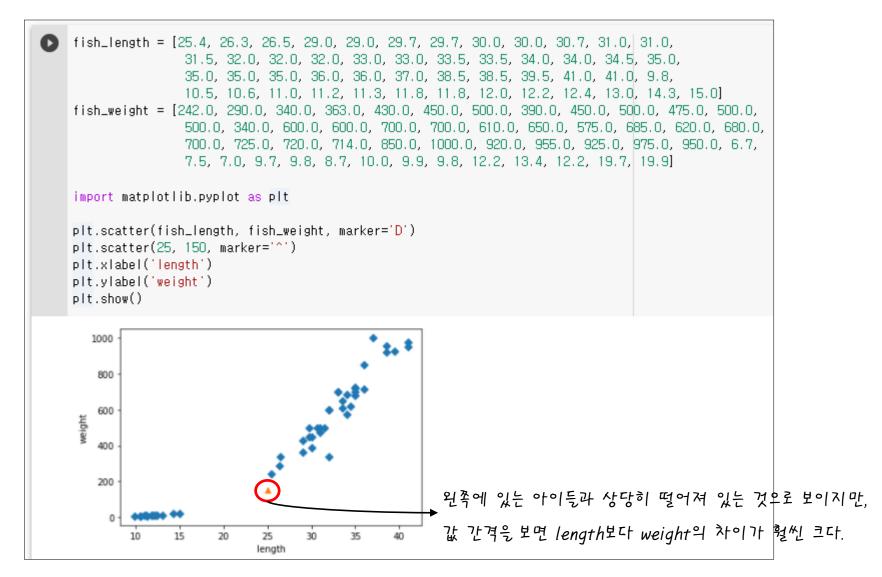
pandas : get_dummies

```
[18] import pandas as pd
    titanic_train = pd.read_csv('/content/sample_data/train.csv')
     titanic_train.Sex
              male
            female
            female
            female
             male
             male
     888
            female
              male
             male
     Name: Sex, Length: 891, dtype: object
    Sex_OneHot = pd.get_dummies(titanic_train.Sex)
     Sex_OneHot
           female male
     891 rows × 2 columns
```

pandas 만세 !!

Data Preprocessing

Why Scaler ???



※ 출처 : 혼자 공부하는 머신러닝+딥러닝 (한빛미디어)

Scaler

스케일링은 통해 다차원의 값든은 비교 분석하기 쉽게 만든어주며, 자료의 오버 픈로우(overflow)나 언더 픈로우(underflow)를 방지 하고, 독립 변수의 공분산 행렬의 조건수(condition number)를 감소시켜 최적화 과정에서의 안정성 및 수렴 속도를 향상 시킨다.

argument에서의 작은 변화의 비율에 대해 함수가 얼마나 변화할 수 있는지 에 대한 argument measure이다. 조건수가 크면 약간의 오차만 있어도 해가 전혀 다른 값은 가진다. 따라서 조건수가 크면 회귀분석은 사용한 예측 값도 오차가 커지게 된다.

	종류	설명	
1	StandardScaler	기본 스케일. 평균과 표준편차 사용]
2	MinMaxScaler	최대/최소값이 각각 1, 0이 되도록 스케일링	- 아웃라이어의 영향 큐
3	MaxAbsScaler	최대절대값과 0이 각각 1, 0이 되도록 스케일링	
4	RobustScaler	중앙값(median)과 IQR(interquartile range) 사용.	아웃라이어의 영향을 최소화

※ 출처: https://mkjjo.github.io/python/2019/01/10/scaler.html

pandas : describe & matplot

```
[27] from sklearn.datasets import load_iris
     import pandas as pd
    iris = load_iris()
     iris_df = pd.DataFrame(data=iris.data, columns=iris.feature_names)
    iris_df
          sepal length (cm) sepal width (cm) petal length (cm) petal width (cm)
                           5.1
                                                3.5
                                                                     1.4
                                                                                         0.2
                            4.9
                                                3.0
                                                                     1.4
                                                                                         0.2
                            4.7
                                                3.2
                                                                     1.3
                                                                                         0.2
                            4.6
                                                3.1
                                                                     1.5
                                                                                         0.2
                            5.0
                                                3.6
                                                                                         0.2
     145
                           6.7
                                                3.0
                                                                     5.2
                                                                                         2.3
                           6.3
                                                2.5
                                                                     5.0
                                                                                         1.9
     146
                           6.5
                                                3.0
                                                                     5.2
                                                                                         2.0
     147
                            6.2
                                                3.4
                                                                     5.4
     148
                                                                                         2.3
                           5.9
                                                3.0
                                                                                         1.8
     150 rows × 4 columns
    iris_df.describe()
            sepal length (cm) sepal width (cm) petal length (cm) petal width (cm)
                      150.000000
                                           150.000000
                                                                150.000000
                                                                                     150.000000
     count
                        5.843333
                                            3.057333
                                                                  3.758000
                                                                                      1.199333
     mean
      std
                        0.828066
                                            0.435866
                                                                  1.765298
                                                                                      0.762238
      min
                        4.300000
                                            2.000000
                                                                  1.000000
                                                                                      0.100000
      25%
                        5.100000
                                            2.800000
                                                                  1.600000
                                                                                      0.300000
      50%
                        5.800000
                                            3.000000
                                                                  4.350000
                                                                                      1.300000
      75%
                        6.400000
                                            3.300000
                                                                  5.100000
                                                                                      1.800000
                                                                                      2.500000
                        7.900000
                                            4.400000
                                                                  6.900000
      max
```

```
[29] iris_df.var()
     sepal length (cm)
                             0.685694
     sepal width (cm)
                             0.189979
                             3.116278
     petal length (cm)
     petal width (cm)
                            0.581006
     dtype: float64
     import matplotlib.pyplot as plt
     iris_df.plot(kind='kde', title='Raw data')
     plt.show()
                                Raw data
        1.0
                                              sepal length (cm)
                                              sepal width (cm)
                                              petal length (cm)
        0.8
                                              petal width (cm)
        0.6
        0.2
```

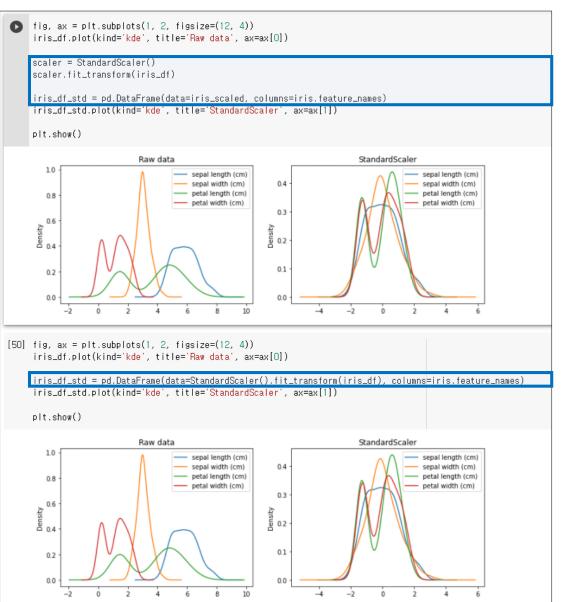
preprocessing: StandardScaler

```
from sklearn.datasets import load_iris
import pandas as pd
iris = load_iris()
iris_df = pd.DataFrame(data=iris.data, columns=iris.feature_names)
import matplotlib.pyplot as plt
fig. ax = plt.subplots(1, 2, figsize=(12, 4))
iris_df.plot(kind='kde', title='Raw data', ax=ax[0])
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
scaler.fit(iris_df)
iris_scaled = scaler.transform(iris_df)
iris_df_std = pd.DataFrame(data=iris_scaled, columns=iris.feature_names)
| iris_df_std.plot(kind='kde', title='StandardScaler', ax=ax[1])
|plt.show()
                        Raw data
                                                                         StandardScaler

    sepal length (cm)

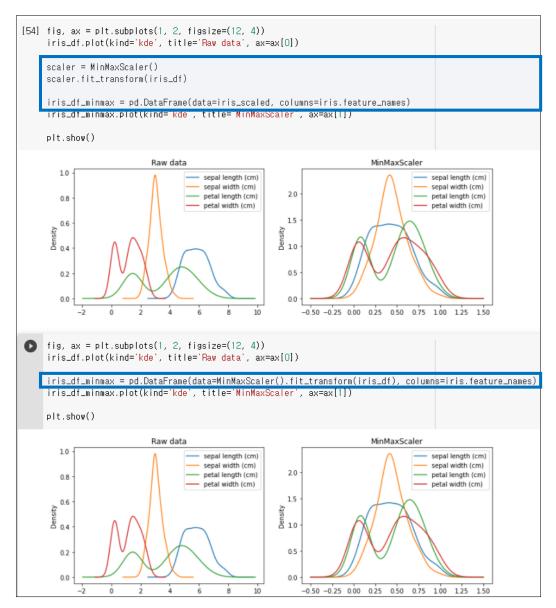
    sepal length (cm)

                                    sepal width (cm)
                                                                                       sepal width (cm)
                                                                                       petal length (cm)
                                    petal length (cm)
                                    petal width (cm)
                                                                                       petal width (cm)
                                                     5 0.2
                                                       0.1
   0.2
   0.0
```

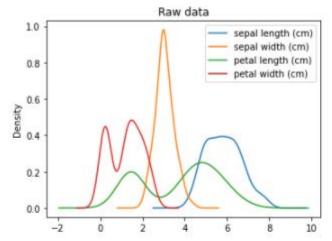


preprocessing: MinMaxScaler

```
from sklearn.datasets import load_iris
import pandas as pd
iris = load_iris()
iris_df = pd.DataFrame(data=iris.data, columns=iris.feature_names)
import matplotlib.pyplot as plt
fig. ax = plt.subplots(1, 2, figsize=(12, 4))
iris_df.plot(kind='kde', title='Raw data', ax=ax[0])
from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler()
scaler.fit(iris_df)
iris_scaled = scaler.transform(iris_df)
iris_df_minmax = pd.DataFrame(data=iris_scaled, columns=iris.feature_names)
iris_df_minmax.plot(kind='kde', title='MinMaxScaler', ax=ax[1])
plt.show()
                        Raw data
                                                                         MinMaxScaler
   1.0
                                   sepal length (cm)
                                                                                      sepal length (cm)
                                   sepal width (cm)
                                                                                       sepal width (cm)
                                                      2.0
                                                                                      petal length (cm)
                                   petal length (cm)
   0.8
                                                                                      petal width (cm)
                                   petal width (cm)
                                                      1.5
   0.6
                                                    8 10
 0 0 4
                                                      0.5
   0.2
   0.0
                                                          -0.50 -0.25 0.00 0.25 0.50 0.75 1.00 1.25 1.50
```



preprocessing: Standard vs MinMaxScaler



표준학 (Standardization)

- 가우시 안 정규 분포로 변환 (평균 O, 분산 /)

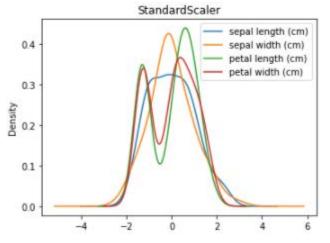
정규학 (Normalization)

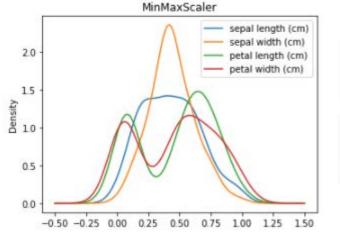
- 각 디처의 크기른 통일하기 위해 변환

$$x_i _new = \frac{x_i - mean(x)}{stdev(x)}$$

mean(x) : 디처 x의 명권

stdev(x): 디처 x의 표준면차





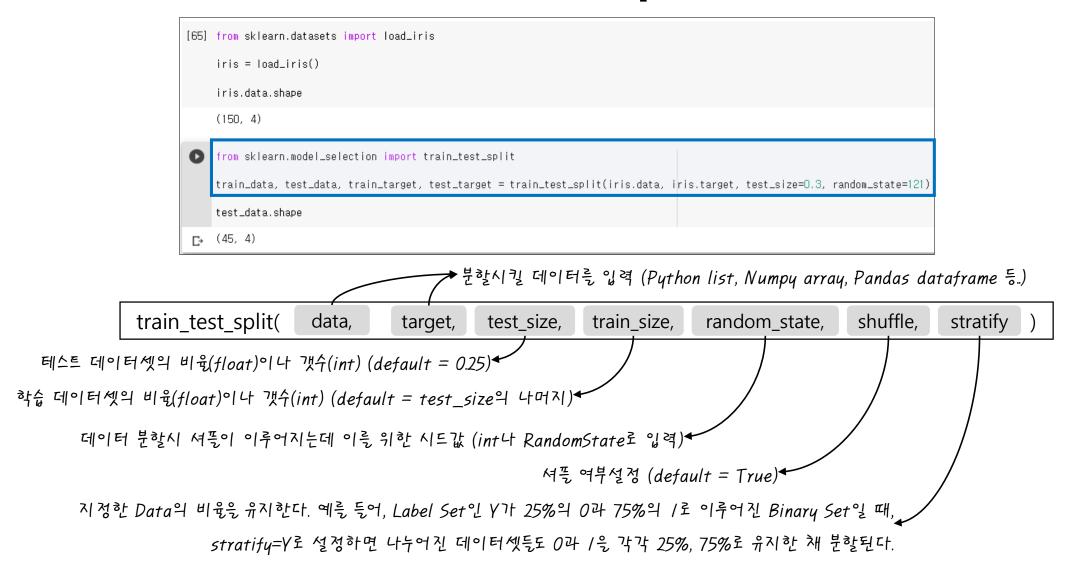
$$x_i _new = \frac{x_i - \min(x)}{\max(x) - \min(x)}$$

$$x_i_new = rac{x_i}{\sqrt{x_i^2 + y_i^2 + z_i^2}}$$

sklearn의 normalization은 선형대수의 normalization은 적용

Train/Test Split

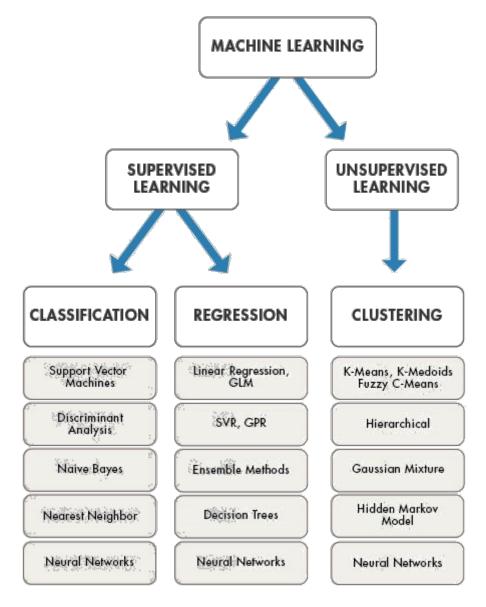
model_selection : train_test_split()



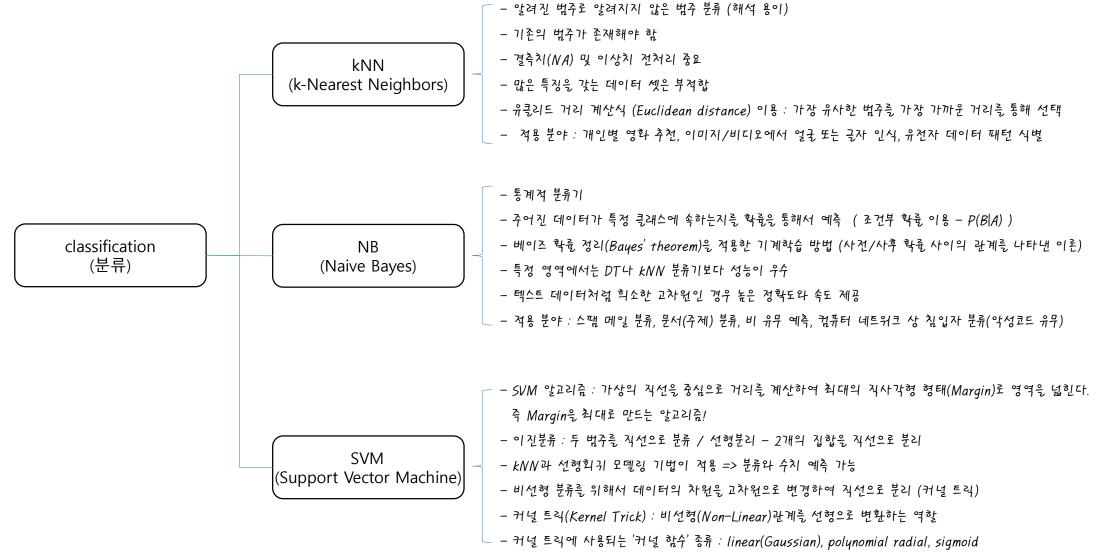
※ 출처: http://blog.naver.com/PostView.nhn?blogId=siniphia&logNo=221396370872

Training

Machine Learning Algorithm



Classification



※ 출처: https://scikit-learn.org/stable/auto_examples/tree/plot_iris_dtc.html

Decision Tree Learning

어떤 항목에 대한 관측값과 목표값은 연결시켜주는 예측 모델

트리 모델 중 목표 변수가 유한한 수의 값은 가지는 것은 분류 트리라 한다.

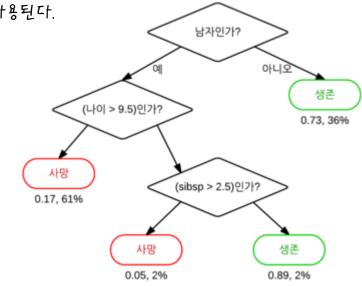
이 트리 구조에서 잎(리프 노드)은 클래스 라벨은 나타내고 가지는 클래스 라벨라 관련 있는 특징들의 논리급은 나타낸다.

결정 트리 중 목표 변수가 연속하는 값, 일반적으로 실수를 가지는 것은 회귀 트리라 한다.

의사 결정 분석에서 결정 트리는 시각적이고 명시적인 방법으로 의사 결정 과정과 결정된 의사를 보여주는데 사용된다.

데이터 마이닝 분야에서 결정 트리는 결정된 의사보다는 자료 자체를 표현하는데 사용된다.

다만, 데이터 마이닝의 결과로서의 분류 트리는 의사 결정 분석의 입력 값으로 사용될 수 있다.



※ 출처: https://ko.wikipedia.org/wiki/결정_트리_학습법

Decision Tree Learning

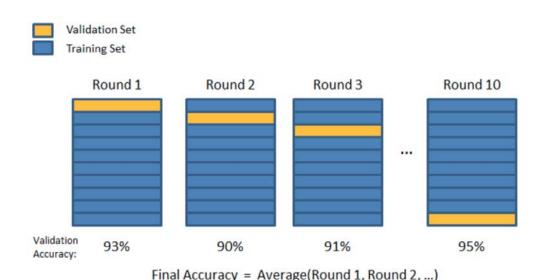
```
from sklearn.datasets import load_iris
    from sklearn.model_selection import train_test_split
    from sklearn.tree import DecisionTreeClassifier
    from sklearn.metrics import accuracy_score
    iris = load_iris()
    train_data, test_data, train_target, test_target = train_test_split(iris.data, iris.target, test_size=0.3, random_state=121)
    dt_clf = DecisionTreeClassifier()
    dt_clf.fit(train_data, train_target)
    pred = dt_clf.predict(test_data)
    print('예측 정확도: {0:.4f}'.format(accuracy_score(test_target, pred)))
    예측 정확도: 0.9556
                                                                                from sklearn.datasets import load_iris
                                                                                    import pandas as pd
                                                                                    from sklearn.preprocessing import MinMaxScaler
                                                                                    from sklearn.model_selection import train_test_split
                                                                                    from sklearn.tree import DecisionTreeClassifier
                                                                                    from sklearn.metrics import accuracy_score
                                                                                    | iris = load_iris()
                                                                                    iris_df = pd.DataFrame(data=iris.data, columns=iris.feature_names)
                                                                                    scaler = MinMaxScaler()
                                                                                    scaler.fit(iris_df)
                                                                                    iris_scaled = scaler.transform(iris_df)
                                                                                    train_data, test_data, train_target, test_target = train_test_split(iris_scaled, iris.target, test_size=0.3, random_state=121)
                                                                                    dt_clf = DecisionTreeClassifier()
                                                                                    dt_clf.fit(train_data, train_target)
                                                                                    pred = dt_clf.predict(test_data)
                                                                                   print('예측 정확도: {0:.4f}'.format(accuracy_score(test_target, pred)))
                                                                                    예측 정확도: 0.9556
```

KNeighborsClassifier

```
from sklearn.datasets import load_iris
 from sklearn.model_selection import train_test_split
 from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score
iris = load_iris()
train_data, test_data, train_target, test_target = train_test_split(iris.data, iris.target, test_size=0.3, random_state=121)
dt_clf = KNeighborsClassifier()
dt_clf.fit(train_data, train_target)
pred = dt_clf.predict(test_data)
print('예측 정확도: {0:.4f}'.format(accuracy_score(test_target, pred)))
예측 정확도: 0.9556
                                                                               from sklearn.datasets import load_iris
                                                                                import pandas as pd
                                                                                from sklearn.preprocessing import MinMaxScaler
                                                                                from sklearn.model_selection import train_test_split
                                                                                from sklearn.neighbors import KNeighborsClassifier
                                                                                from sklearn.metrics import accuracy_score
                                                                                iris = load_iris()
                                                                                iris_df = pd.DataFrame(data=iris.data, columns=iris.feature_names)
                                                                                scaler = MinMaxScaler()
                                                                                scaler.fit(iris_df)
                                                                                iris_scaled = scaler.transform(iris_df)
                                                                                train_data, test_data, train_target, test_target = train_test_split(iris_scaled, iris,target, test_size=0.3, random_state=121)
                                                                               dt_clf = KNeighborsClassifier()
                                                                                dt_clf.fit(train_data, train_target)
                                                                                pred = dt_clf.predict(test_data)
                                                                               print((예측 정확도: {0:.4f}'.format(accuracy_score(test_target, pred)))
                                                                                예측 정확도: 0.9778
```

Validate / Tuning

model_selection : KFold()



index 값에서 보이는 것라 같이,

KFold는 그냥 순서대로 잘라내서 분할해준다.

→ 북균형한 데이터 분포인 경우 문제가 있은 수 있다!

```
from sklearn.datasets import load_iris
 from sklearn.model_selection import KFold
iris = load_iris()
print("Raw Size : %s" % iris.data.shape[0])
kfold = KFold(n_splits=5)
for n_iter, (train_index, test_index) in enumerate(kfold.split(iris.data), start=1):
  train_data, test_data = iris.data[train_index], iris.data[test_index]
  train_target, test_target = iris.target[train_index], iris.target[test_index]
  print("n_iter=%s, train size=%s, test size=%s" % (n_iter, train_data.shape[0], test_data.shape[0]))
  print(" index : %s" % test_index)
Raw Size : 150
n_iter=1, train size=120, test size=30
  index : [ 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23
 24 25 26 27 28 291
n_iter=2, train size=120, test size=30
   index : [30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53
 54 55 56 57 58 59]
n_iter=3, train size=120, test size=30
   index : [60 61 62 63 64 65 66 67 68 69 70 71 72 73 74 75 76 77 78 79 80 81 82 83
 84 85 86 87 88 891
n_iter=4, train size=120, test size=30
  index : [ 90 91 92 93 94 95 96 97 98 99 100 101 102 103 104 105 106 107
 108 109 110 111 112 113 114 115 116 117 118 119]
n_iter=5, train size=120, test size=30
   index : [120 121 122 123 124 125 126 127 128 129 130 131 132 133 134 135 136 137
 138 139 140 141 142 143 144 145 146 147 148 1491
```

교차검증

model_selection : StratifiedKFold()

```
from sklearn.datasets import load_iris
 from sklearn.model_selection import StratifiedKFold
 iris = load_iris()
 print("Raw Size : %s" % iris.data.shape[0])
 skfold = StratifiedKFold(n_splits=5)
 for n_iter, (train_index, test_index) in enumerate(skfold.split(iris.data,iris.target), start=1):
   train_data, test_data = iris.data[train_index], iris.data[test_index]
  train_target, test_target = iris.target[train_index], iris.target[test_index]
  print("n_iter=%s, train size=%s, test size=%s" % (n_iter, train_data.shape[0], test_data.shape[0]))
  print(" index : %s" % test_index)
 Raw Size : 150
 n_iter=1, train size=120, test size=30
  index : [ 0  1  2  3  4  5  6  7  8  9 50 51 52 53 54 55 56 57
   58 59 100 101 102 103 104 105 106 107 108 109]
 n_iter=2, train size=120, test size=30
  index: [ 10 11 12 13 14 15 16 17 18 19 60 61 62 63 64 65 66 67
  68 69 110 111 112 113 114 115 116 117 118 119]
n_iter=3, train size=120, test size=30
  index : [ 20 21 22 23 24 25 26 27 28 29 70 71 72 73 74 75 76 77
  78 79 120 121 122 123 124 125 126 127 128 1291
n_iter=4, train size=120, test size=30
  index : [ 30 31 32 33 34 35 36 37 38 39 80 81 82 83 84 85 86 87
  88 89 130 131 132 133 134 135 136 137 138 139]
n_iter=5, train size=120, test size=30
  index : [ 40 41 42 43 44 45 46 47 48 49 90 91 92 93 94 95 96 97
   98 99 140 141 142 143 144 145 146 147 148 1491
```

→ target 분포에 맞취서 데이터를 분류해준다.

model_selection : cross_val_score()

```
from sklearn.datasets import load_iris
from sklearn.tree import DecisionTreeClassifier
from sklearn.model_selection import train_test_split, cross_val_score, cross_validate
import numpy as np

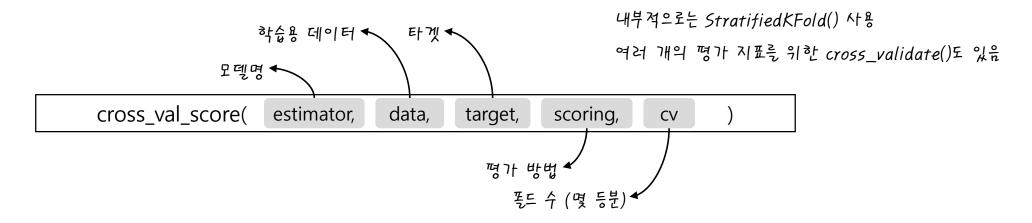
iris = load_iris()

train_data, test_data, train_target, test_target = train_test_split(iris.data, iris.target, test_size=0.3, random_state=121)

dt_clf = DecisionTreeClassifier()

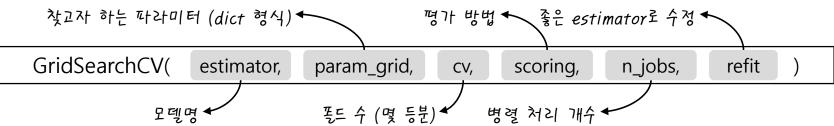
scores = cross_val_score(dt_clf, train_data, train_target, scoring='accuracy', cv=3)
print('교차 검증별 정확도 :', np.round(scores, 4))
print('평균 검증 정확도 :', np.round(np.mean(scores), 4))

교차 검증별 정확도 : [0.9429 0.9143 0.9429]
평균 검증 정확도 : 0.9333
```



model_selection : GridSearchCV() - 1/2





model_selection : GridSearchCV() - 2/2

```
from sklearn.datasets import load_iris
    from sklearn.tree import DecisionTreeClassifier
    from sklearn.model_selection import train_test_split, GridSearchCV
    from sklearn.metrics import accuracy_score
    iris = load_iris()
    train_data, test_data, train_target, test_target = train_test_split(iris.data, iris.target, test_size=0.3, random_state=121)
    dt_clf = DecisionTreeClassifier()
    parameters = {'max_depth' : [1,2,3], 'min_samples_split' : [2,3]}
    dt_grid = GridSearchCV(dt_clf, param_grid=parameters, cv=3, refit=True)
    dt_grid.fit(train_data, train_target)
    model = dt_grid.best_estimator_
    pred = model.predict(test_data)
    print('예측 정확도: {0:.4f}'.format(accuracy_score(test_target, pred)))
    예측 정확도: 0.9556
```

https://kahoot.it